



مدل های زبانی بزرگ (بهار ۱۴۰۵)

تمرین کامپیوتری دوم

مهلت ارسال: ۱۴۰۵/۰۲/۱۸

استاد درس: دکتر دوستی

طراحان تمرین:

- امیرارسلان نعمت الهی (a.nematollahi@ut.ac.ir)

- ریحانه یوردخانی (r.yourdkhani@ut.ac.ir)

قوانین و ملاحظات

نحوه ارسال تمرین:

- تمامی فایل ها باید در یک فایل فشرده با نام LLM-CA2-StudentID ارسال شوند.
- تمامی کدهای ارسال شده باید امکان اجرای مجدد داشته باشند. اگر تنظیمات خاصی برای اجرا نیاز است، آن را ذکر کنید.
- کدهای ارسال شده باید توسط خودتان اجرا شده باشند و نتایج اجرا در فایل ارسالی مشخص باشد.

رعایت اصول آکادمیک و صداقت علمی:

- این تمرین باید به صورت فردی انجام شود. هرگونه همکاری یا نوشتن تمرین به صورت گروهی ممنوع است.
- در صورت مشاهده تشابه در پاسخ، تمامی افراد درگیر، نمره صفر دریافت خواهند کرد و موضوع به استاد گزارش خواهد شد.

استفاده از ابزارهای هوش مصنوعی:

استفاده از ابزارهایی مانند Copilot، Gemini، ChatGPT و موارد مشابه مجاز است، اما تحت شرایط زیر:

- نحوه استفاده از این ابزارها را در انتهای نوتبوک خود توضیح دهید (ابزارهای استفاده شده، کاربردهای مشخص و موارد مرتبط).

- تمامی پرامپت ها و لینکهای استفاده شده را در انتهای نوتبوک و در یک سلول قرار دهید.
- عدم ارائه این اطلاعات به منزله سرقت علمی محسوب شده و منجر به نمره صفر خواهد شد.

ارتباط با TA ها و پرسیدن سوال:

- دانشجویان میتوانند تمامی سوالات مرتبط به تمرین خود را در گروه درس و یا با ایمیل با TA طراح سوال مطرح کنند.

- در تمامی پرسش ها حتما ایمیل دستیاران ارشد درس باید cc شود.

○ علی رمضانی – ali.ramezani.96@ut.ac.ir

○ علی خرم فر – Khoramfar@ut.ac.ir

مهلت ارسال و جریمه تأخیر:

- امکان ارسال تمرین با تأخیر تا ۲ روز وجود دارد. برای هر روز تأخیر **۱۵ درصد جریمه** اعمال میشود.
- تأخیر به صورت ساعتی محاسبه شده و پس از دو روز تأخیر، تمرین پذیرفته نخواهد شد.
- مهلت ارسال عادی این تمرین تا پایان روز ۱۸ اردیبهشت ماه ۱۴۰۵ و مهلت ارسال با تأخیر تا پایان روز ۲۰ اردیبهشت ماه ۱۴۰۵ می باشد.

بخش اول :

Prompt Engineering, In-Context Learning, and Instruction Tuning

در این تمرین، هدف شما آشنایی عملی با روش‌های مهندسی prompt و بهینه‌سازی و اصلاح prompt ها در فاز inference و در نتیجه بهبود پاسخدهی مدل بدون نیاز به هیچگونه ای از training و fine-tuning میباشد. این روش‌ها به شما اجازه می‌دهند مدل را برای تولید دقیق‌ترین، مرتبط‌ترین و باکیفیت‌ترین خروجی ممکن هدایت کنید.

در این تمرین شما از مدل google/gemma-3-270m-it با استفاده از mirror داخلی مشخص شده در فایل notebook (devneeds.ir) استفاده خواهید کرد. برای قسمت‌های سوالات تشریحی و توضیحات خودتان در بخش‌های مختلف، میتوانید به فارسی توضیحات را وارد کنید. البته در کدها و پرامپت‌دهی‌های مختلف به مدل، پیشنهاد میشود به همان زبان انگلیسی این کار را انجام دهید تا بتوانید به نتایج مطلوب برسید.

در فایل نوت‌بوک پیوست، توضیحات تکمیلی مربوط به هر بخش ارائه شده است. انتخاب مدل و طراحی سوالات به گونه‌ای بوده است که به راحتی بتوان با cpu کدها را run کرد. لازم است کدهای خود را در همان نوت‌بوک وارد کرده و قسمت‌های مورد نیاز را تکمیل کنید. تهیه گزارش به صورت فایل PDF جداگانه نیاز نیست؛ پاسخ‌ها و توضیحات خود را مستقیماً در همان نوت‌بوک بنویسید. مطمئن شوید که توضیحات شما کامل، دقیق و خوانا هستند چرا که قسمت زیادی از نمره به همین مورد بستگی دارد.

بخش دوم:

LoRA Fine-tuning

در این تمرین، هدف شما آشنایی عملی با روش‌های Parameter-Efficient Fine-Tuning (PEFT) و به‌طور خاص تکنیک LoRA است. این روش‌ها به شما اجازه می‌دهند بدون نیاز به منابع محاسباتی سنگین، یک مدل زبانی از پیش آموزش دیده را تنها با تعداد بسیار کمی پارامتر آموزش دهید.

در این سوال شما:

- مجموعه داده‌ی IMDb را برای تحلیل sentiment آماده می‌کنید.
 - یک Dataset و DataLoader سفارشی برای توکن‌سازی می‌سازید.
 - مدل ALBERT-base-v1 را بارگذاری می‌کنید.
 - لایه‌های LoRA را روی لایه‌های توجه مدل اعمال می‌کنید.
 - مدل را روی بخشی از داده‌ها فاین‌تیون می‌کنید.
 - سپس مدل پایه و مدل فاین‌تیون شده را از نظر عملکرد با یکدیگر مقایسه می‌کنید.
- توضیحات تکمیلی هر بخش در نوت‌بوک پیوست آورده شده است. کدهای خود را در آنجا آپلود و تکمیل کنید. به سوالات پرسیده شده در نوت‌بوک توجه کنید. آنالیز شما از نتایج به دست آورده شده بخش مهمی از نمره شما را در بر می‌گیرد. نیازی به تهیه گزارش به صورت pdf نیست و می‌توانید پاسخ‌های خود را در همان نوت‌بوک بنویسید. در این صورت از توضیحات کامل و خوانایی توضیحات خود مطمئن باشید.